



**Hochschule
Bonn-Rhein-Sieg**
University of Applied Sciences

Projektarbeit

PostgresSQL - Rekursion auf Basis generischer Stored Procedures

Fachbereich Informatik
Referent: Prof. Dr. Harm Knolle

eingereicht von:
Jennifer Wittling, Rolf Kimmelman, Jan Löffelsender

Sankt Augustin, den 09.12.2018

Zusammenfassung

In den letzten Jahren haben Graphdatenbanken an Bedeutung gewonnen, da sich mit diesen bestimmte Fragestellungen besonders schnell lösen lassen. Graphdatenbanken haben den Vorteil, dass sich insbesondere Beziehungen zwischen Objekten gut abbilden und sehr performant abfragen lassen. Bei relationalen Datenbanken ist es zur Darstellung von Beziehungen zwischen Objekten erforderlich die verschiedenen Tabellen mittels des JOIN Operators zu verknüpfen. Diese Verknüpfungen können schnell zu einem großen Rechenaufwand und langen Laufzeiten führen. Es soll am Beispiel von Postgres untersucht werden, ob und wie sich Graphen in relationalen Datenbanken abbilden lassen. Weiterhin soll analysiert werden, ob und für welche Problemstellungen es sinnvoller ist Graphen in einer relationalen Datenbank statt einer Graphdatenbank abzubilden. Ist es zukünftig notwendig für die performante Verarbeitung steigender Datenmengen auf neue Technologien, wie Graphdatenbanken zu schwenken oder lassen sich die klassischen relationalen Datenbanken so erweitern, dass diese Problemstellungen ähnlich effizient lösen können.

Not only SQL (NoSQL) Datenbanken und insbesondere Graphdatenbanken sind im Gegensatz zu den relationalen Datenbanken flexibler und bei der Lösung bestimmter Probleme weniger rechen- und speicherintensiv. Insbesondere wenn es um die Auflösung von Beziehungen bzw. um die Traversierung über einen Graphen geht, bieten Graphdatenbanken Vorteile gegenüber den herkömmlichen relationalen Datenbanken. In der Praxis wurde jedoch auch die Beobachtung gemacht, dass durch die Verwendung von Stored Procedures die Traversierung über einen Graphen mittels einer relationalen Datenbank ähnlich schnell umgesetzt werden kann, wie mit einer Graphdatenbank.

Es soll das Modell als grundlegender technologische Aspekt von Graphdatenbanken kurz erläutert werden. Zielsetzung dieser Arbeit ist es einen Graphen in der relationalen Datenbank Postgres abzubilden und zu vergleichen, wie sich die Traversierung über diesen Graphen effizient umsetzen lässt. Zunächst soll die Umsetzung mittels klassischer SQL Operationen erfolgen. Anschließend sollen die Problemstellungen mittels Stored Procedures, sowie der Rekursion mittels PL/SQL gelöst werden. Die Ergebnisse der verschiedenen Vorgehensweisen sollen miteinander verglichen werden.

Inhaltsverzeichnis

Zusammenfassung	II
1 Graph-Datenbanken - Grundlegende technologische Aspekte	1
1.1 Modell	1
1.1.1 Graph	1
1.1.2 Bäume	3
1.1.3 Property Graphen	3
1.1.4 Hypergraphen	4
2 Graph-Datenbanken und -Frameworks - Ausgewählte Systeme	6
2.1 PostgreSQL	6
2.1.1 Visitenkarte des Systems	6
3 Graph-Datenbanken im praktischen Einsatz: Online Transaction Processing (OLTP)	8
3.1 PostgreSQL: OLTP	8
3.1.1 Installation von Postgres	8
3.1.2 CSV-Import	9
3.1.3 Datenbankschema	9
3.1.4 Erstellen von Fremdschlüsseln	9
3.1.5 Graphtraversierung mit Hilfe von Standard Structured Query Language (SQL)	9
3.1.6 Graphtraversierung mit Hilfe von verschachteltem SELECT Statement	10
3.1.7 Graphtraversierung mit Hilfe von rekursiven INNER JOIN . .	11
3.1.8 Graphtraversierung mit Hilfe von selbstgeschriebenen Stored Procedure	11
4 Graph-Datenbanken im praktischen Einsatz: OLAP	13
4.1 PostgreSQL: OLAP	13
4.1.1 Benchmark	13
4.1.2 Antwortzeiten mit partitionierten Tabellen und Indices	20
4.1.3 Standard SQL	20
4.1.4 Stored Procedures	20
4.1.5 PL/SQL-Recursion	20
4.1.6 Datenbankzugriffe	20
4.1.7 Zugriffsart Aggregation	20
4.1.8 Zugriffsart Traversierung	20

4.1.9 Interpretation der Ergebnisse	20
A Anhang	21
A.1 Graph-Datenbanken - Grundlegende technologische Aspekte	21
A.2 Graph-Datenbanken und -Frameworks - Ausgewählte Systeme	21
A.3 Graph-Datenbanken im praktischen Einsatz: OLTP	21
A.4 Graph-Datenbanken im praktischen Einsatz: OLAP	23
Abbildungsverzeichnis	24
Tabellenverzeichnis	25
Listings	26
Abkürzungsverzeichnis	26
Literaturverzeichnis	28
Eidesstattliche Erklärung	30

1 Graph-Datenbanken - Grundlegende technologische Aspekte

1.1 Modell

Ein Modell ist eine vereinfachte bzw. abstrahierte Darstellung von realen Gegenständen, Sachverhalten oder Problemen. Durch die Modellierung soll die Realität auf die wichtigsten Einflussfaktoren reduziert werden. Die Graphentheorie spielt eine zentrale Rolle bei der Modellierung von Problemen und Sachverhalten, da sich Graphen sehr gut zur Darstellung vernetzter Daten eignen. Da eine effiziente Verarbeitung von großen vernetzten Datenmengen immer wichtiger wird, haben Graphen in den letzten Jahren auch eine bedeutende Rolle in der Datenbankwelt erhalten. Im folgenden sollen verschiedene Aspekte der Graphentheorie, die zur Modellierung von Graphdatenbanken von Bedeutung sind, kurz vorgestellt werden.

1.1.1 Graph

Ein Graph ist mathematisch folgendermaßen definiert:

Definition. *Ein Graph $G = (V, E, \gamma)$ ist ein Tripel bestehend aus:*

- V , einer nicht leeren, ungeordneten Menge von Knoten (vertices)
- E , einer Menge von Kanten (edges)
- γ , einer Inzidenzabbildung (incidence relation), mit
 $\gamma : E \longrightarrow \{X | X \subseteq V, 1 \leq |X| \leq 2\}$


Ein Knoten repräsentiert ein Element in einem Graphen und die Kanten stellen die Beziehung zwischen den einzelnen Knoten her. In einem einfachen Graphen kann eine Kante immer nur jeweils zwei Knoten miteinander verbinden. Zwei Knoten heißen adjazent, wenn diese über eine Kante direkt miteinander verbunden sind. Eine Kante die mit einem Knoten verbunden ist wird als inzident zu diesem Knoten bezeichnet.[KK15]

Graphen können gerichtet oder ungerichtet sein. Gerichtete Graphen zeichnen sich dadurch aus, dass die Kanten eine zugewiesene Richtung besitzen. Grafisch werden gerichtete Kanten in der Regel durch Pfeile dargestellt. Für die Modellierung von realen Gegebenheiten ist das Konzept der gerichteten Graphen sehr entscheidend, da dieses die Darstellung einseitiger Beziehungen zwischen den Entitäten des Modells erlaubt.

Um die Beziehung zwischen zwei Knoten genauer zu definieren, lassen sich die Kanten gewichten. Dabei werden den Kanten in der Regel numerische Werte zugeordnet und man bezeichnet diese Graphen als Gewichtete Graphen. Durch die Wichtung von Kanten lassen sich beispielsweise Kosten oder Distanzen zwischen den Entitäten definieren.

Ein Knoten ist isoliert, wenn er keine inzidenten Kanten und somit keine direkten Nachbarn hat.[KK15] Ein ungerichteter Graph heißt zusammenhängend, falls es zwischen zwei beliebigen Knoten a und b aus V einen ungerichteten Weg mit a als Startknoten und b als Endknoten gibt.[KN12, 36-38] Hat eine Kante als Start- und Endknoten den selben Knoten, verbindet also den Knoten mit sich selber, spricht man von einer Schlinge. Liegen zwischen zwei Knoten eines Graphen mehr als eine Kante, nennt man diese Multikante. Enthält ein Graph Multikanten und Schlingen ist dies kein einfacher Graph mehr sondern ein Multigraph.[SF05]

Der Grad eines Knoten bezeichnet die Anzahl der inzidenten Kanten des Knoten. Dabei werden Schleifen doppelt gezählt.[Rah17b, Seite 13] Ein Graph, bei dem alle Knoten den selben Knotengrad haben, wird als regulärer Graph bezeichnet.[Fel03] Abbildung 1.1.1 zeigt einen regulären Graphen mit Knotengrad null und einen mit einem Grad von drei.



Sind bei einem Graphen alle Knoten mit allen übrigen Knoten verbunden spricht man von einem vollständigen Graphen:


$$K_n = ([n], \binom{[n]}{2})$$

Da bei einem Graphen nur die Struktur definiert ist, also welcher Knoten über welche Kante mit den anderen Knoten verbunden ist, können Graphen auf unterschiedli-

che weisen gezeichnet werden und trotzdem gleich sein. Sind zwei Graphen gleich, bezeichnet man diese als isomorph.[Rah17a, Seite 22]

1.1.2 Bäume


Ist ein Graph kreisfrei, es gibt keinen Weg bei dem der Start- gleich dem Endknoten ist, spricht man von einem Wald. Sind die Knoten eines Waldes zusammenhängend entsteht ein Baum. Ein Baum mit n Knoten hat immer $n - 1$ Kanten.[Rah17a] Knoten mit dem Grad $n = 1$ werden als Blätter bezeichnet. Bäume können gerichtet und ungerichtet sein. Im Falle von gerichteten Bäumen spricht man auch von gewurzelten Bäumen, da der Ursprungsknoten als Wurzel bezeichnet wird. Abbildung 1.1.2 zeigt einen gewurzelten Baum, die Blätter sind hier grün dargestellt und die Wurzel rot. In einem Baum gibt es zwischen zwei beliebigen Knoten immer nur einen Weg. Bei einem gewurzelten Baum werden die Ausgangsknoten als Eltern und die Zielknoten jeweils als Kinder der Ausgangsknoten bezeichnet. Hat in einem gewurzelten Baum jeder Knoten maximal zwei Kinder, wird dieser als Binärbaum bezeichnet.[Rah17a]



1.1.3 Property Graphen

Propertygraphen erweitern das Modell des einfachen Graphen. Property Graphen sind gerichtete Graphen, die sich durch ihre den Kanten und Knoten zugewiesenen Eigenschaften (Properties) auszeichnen. Gespeichert werden diese Eigenschaften als Key-Value-Paare. Label ermöglichen die Unterteilung von Knoten und Kanten in verschiedene Knoten- und Kantentypen. Attribute, Label und die Richtung der Kanten erlauben eine sehr detaillierte modellierung von realen Sachverhalten. Somit sind Property Graphen von sehr großer Bedeutung für Graphdatenbanken.

Abbildung 1.1.3 zeigt einen Property Graphen. Die Knoten sind den drei Labeln Person, Unternehmen und Stadt zugeordnet. Die gerichteten Kanten stellen die Beziehungsverhältnisse zwischen den einzelnen Knoten her und können durch Attribute, wie beispielsweise der Information über die Dauer der bisherigen Beziehung, genauer definiert werden.



1.1.4 Hypergraphen

Hypergraphen stellen eine generalisierung von vormalen Graphen dar. Hypergraphen haben die Eigenschaft, dass Kanten im Gegensatz zu klassischen Graphen mehr als zwei Knoten miteinander verbinden können. Die Kanten des Hypergraphen werden auch als Hyperkanten bezeichnet. Im Falle eines gerichteten Hypergraphen verbindet die Hyperkante den Ausgangsknoten direkt mit allen Zielknoten.


Mathematisch ist ein Hypergraph folgendermaßen definiert:

Definition. Let $X = \{v_1, v_2, \dots, v_n\}$ be a finite set, and let $E = \{e_1, e_2, \dots, e_m\}$ be a family of subsets of X such that

$$e_i \neq \emptyset (i = 1, 2, \dots, m) \cup_{i=1}^m e_i = X.$$

The pair $H = (X, E)$ is called a hypergraph with vertex set X and hyperedge set E . The elements v_1, v_2, \dots, v_n of X are vertices of hypergraph H , and the sets e_1, e_2, \dots, e_m are hyperedges of hypergraph H . [ZSHZ18, Seite 2]

Abbildung 1.1.4 zeigt einen Hypergraphen. Die Kante e_4 verbindet in diesem Graphen die Knoten v_5, v_6 und v_7 miteinander.



Im Vergleich zum normalen Graphen können die Kanten eines Hypergraphen eine beliebige Kardinalität haben (siehe Definition Graph Kapitel 1.2.1). Beim normalen Graphen können die Kanten nur die Kardinalität $1 \leq |X| \leq 2$ haben. Die Hyperedges in einem Hypergraphen sind somit eine beliebige Menge von Knoten.

Da die Hypergraphen eine flexiblere Struktur als das einfache Graphen-Modell bietet, werden diese oft zur Modellierung in Graphdatenbanken verwendet.[Goe15]

2 Graph-Datenbanken und -Frameworks - Ausgewählte Systeme

2.1 PostgreSQL

2.1.1 Visitenkarte des Systems

- Allgemein
 - Name: PostgreSQL, umgangssprachlich Postgres
 - Kategorie / Modell: PostgreSQL ist ein Relationales Datenbank System
 - Version: 11.1
 - Historie: PostgreSQL ist aus dem POSTGRES Projekt der University of California at Berkeley entstanden, welches unter der Leitung von Professor Michael Stonebraker im Jahre 1986 began.
 - Hersteller: PostgreSQL Global Development Group
 - Lizenz: Open-Source
 - Referenzen / Quellenangaben: [Fro18], [Pos18], [Groa], [Eis03]
- Architektur
 - Programmiersprache: C
 - Systemarchitektur: Objektrelationales Datenbankmanagementsystem
 - Betriebsart: Stand Alone, Cluster Betrieb für Replikation der Datenbank
 - Application Programming Interface (API): u.A. libpq, psycopg, psqLODBC, pq, pgtnlg, Npgsql, node-postgres

- Datenmodell
 - Standardsprache: PL/pgSQL
 - Sichten (Views): Ja
 - Externe Dateien (BLOBs): Ja
 - Schlüssel: Ja
 - Semantische unterschiedliche Beziehungen: Ja
 - Constraints: Ja
- Indexe
 - Sekundärindexe: Ja
 - Gespeicherte Prozeduren: Ja
 - Triggermechanismen: Ja, Prozeduren , die als Trigger aufgerufen werden
 - Versionierung: Ja, Versionierung mit Hilfe von Transaktions-ID(XID)
- Abfragemethoden
 - Kommunikation: SQL über Transmission Control Protocol (TCP)/Internet Protocol (IP)
 - Create, Read, Update, Delete (CRUD)-Operationen: Ja
 - Ad-hoc-Anfragen: Ja
- Konsistenz
 - Atomicity, Consistency, Isolation, Durability (ACID), besonders Multiversion Concurrency Control Modell (MVCC)
 - Transaktionen: Ja
 - Nebenläufigkeit (Synchronisation): Ja
- Administration
 - Werkzeuge: pgAdmin, dataGrip, diverse Erweiterungen
 - Massendatenimport: Ja
 - Datensicherung: Ja

3 Graph-Datenbanken im praktischen Einsatz: OLTP

3.1 PostgreSQL: OLTP

Die Implementierung von OLTP Anwendungsfällen ist eine klassische Aufgabe für relationale Datenbanken. Da statt einer Graphdatenbank eine relationale Datenbank verwendet wurde, ist die Implementierung des OLTP Anwendungsfalls (Gästebuch) uninteressant. Interessant ist jedoch die Traversierung in relationalen Datenbanken. Für die Graphtraversierung wurden eigene Scripte geschrieben, die in diesem Kapitel vorgestellt werden. Da Graphdatenbanken für das Traversieren von Graphen entwickelt worden sind, sollten diese bei der Traversierung einen Performancegewinn gegenüber objektrelationalen Datenbanken haben. Ziel ist es mit Hilfe einer objektrelationalen Datenbank eine mit den Graphdatenbanken vergleichbar performante Abfrage eines Graphen zu implementieren. Für die Graphtraversierung sind die folgenden 5 Methoden vorgesehen.

Graphtraversierung mit Hilfe von:

- Rekursiven Common Table Expression (CTE)
- Verschachteltem SELECT Statement
- Rekursiven INNER JOIN
- Selbstgeschriebenen Stored Procedure
- Dynamisch generiertem SQL

3.1.1 Installation von Postgres

PostgreSQL kann unter Ubuntu über die Paketverwaltung Advanced Package Tool (APT) installiert werden. Weiterhin wird eine Installation über die Red Hat Package Manager (RPM)-Paketverwaltung angeboten. Im Rahmen dieser Arbeit wird PostgreSQL Version 11 verwendet. Ein Parallelbetrieb verschiedener PostgreSQL Versionen ist möglich. Nach der Installation von PostgreSQL muss zunächst *initdb* ausgeführt werden. Über *initdb* wird ein PostgreSQL-Cluster angelegt. Als Parame-

ter kann ein Directory-Pfad angegeben werden. In diesem Pfad wird der PostgreSQL-Cluster von *initdb* angelegt. Gemäß der Vorgaben dieser Arbeit wurde das PostgreSQL-Cluster unter */data/team22/postgresql/11/main* installiert.

3.1.2 CSV-Import

Beim Import von (CSV)-Dateien wird zwischen Import vom Clientsystem und Import vom Serversystem unterschieden. Für den Import vom Client wird das `psql`-Statement `\copy` verwendet (siehe SQL Script A.1). `\copy` liest Informationen aus einer Datei, die vom `psql`-Client aus erreichbar sein muss. [Pos18]

3.1.3 Datenbankschema

Für die Performancemessung sind 5 Graphen vorgesehen. Ein Graph besteht aus einer *profiles* Tabelle und einer *relation* Tabelle. Die beiden Tabelle werden mit Hilfe der Spalte *ID* aus der jeweiligen *profiles* Tabelle verknüpft. Die Spalten *src* und *dst* aus der *relation* Tabelle sind Fremdschlüssel, sie verweisen auf die Spalte *ID* in der *profiles* Tabelle. *ID* hingegen ist in der *profiles* Tabelle ein Primärschlüssel (siehe A.3).

3.1.4 Erstellen von Fremdschlüsseln

Um die *profile* Tabelle und die *relation* Tabelle zu verknüpfen wurde zwischen den beiden Tabellen ein Fremdschlüssel erstellt. Bei der Erstellung wurde die *profile* Tabelle mit einem Zähler versehen. Hierbei wurde der `postgres` Befehl `serial` verwendet, der einen Zähler für jede Zeile der Tabelle erstellt und bei 1 startet. Damit die Tabellen *relation* und *profile* mit Hilfe eines Fremdschlüssel verknüpft werden können, muss der Zähler innerhalb der *profile* Tabelle jedoch bei 0 starten. Der Grund dafür ist, dass innerhalb der *relation* Tabelle die *src* und die *dst* Spalte bei 0 anfangen - somit auf ein Profil verweisen, was die *ID* 0 hat. Hierfür wurde für die *relation* Tabelle ein SQL Script geschrieben, was die Daten zuerst in eine temporäre Tabelle schreibt, von jeder Zeile innerhalb der Spalte *ID* 1 subtrahiert und anschließend die Werte aus der temporären Tabelle in die endgültige *profile* Tabelle schreibt (siehe hierzu auch beispielhaft das Script für die Tabelle *facebook-profiles* (siehe A.4).

3.1.5 Graphtraversierung mit Hilfe von Standard SQL

Bei der Graphtraversierung mit Hilfe von Standard SQL wird der Befehl `WITH RECURSIVE` und `UNION` verwendet (siehe A.8). Der SQL Befehl `WITH RECURSIVE` sorgt dafür, dass die Abfrage sich mit der Ergebnismenge wieder selber aufruft. Die

Rekursion operiert hierzu auf 2 temporären Tabellen. Der Working Tabelle und der Intermediate Tabelle. Ein Rekursionsschritt sieht folgendermaßen aus: Die Ergebnisse innerhalb einer Rekursionsstufe werden in die Working Tabelle geschrieben, es wird überprüft ob Duplikate vorhanden sind ¹ - Duplikate werden gelöscht, die Ergebnismenge wird in die Intermediate Tabelle geschrieben, die Ergebnisse aus der Intermediate Tabelle werden in die Working Tabelle kopiert. Im Vergleich zu den restlichen Methoden garantiert das standard SQL falls man den UNION Operator verwendet, dass Kreise ² aus dem Graphen entfernt werden. Die Abbruchbedingung für die Rekursion greift, sobald die Working Tabelle keine Einträge mehr hat. Folgende Grafik beschreibt die Rekursion angewendet auf ein relation Tabelle:




Abbildung 3.1: Traversierung Standard SQL

Es wurde sich dafür entschieden den UNION Operator zu verwenden, um Duplikate innerhalb der Working Tabelle auszuschließen. Für die Ergebnismenge der Abfrage auf der relation Tabelle bedeutet dies, dass die Ergebnismenge ungefähr die Anzahl an Profilen haben sollte. Wohingegen die Abfrage mit UNION ALL, das Duplikate aus der Working Tabelle nicht entfernt ([Grob]), eine Ergebnismenge zurückliefert, die genauso viele Elemente hat wie die jeweilige relation Tabelle.

3.1.6 Graphtraversierung mit Hilfe von verschachteltem SELECT Statement

Bei der Graphtraversierung mit Hilfe von verschachteltem SQL wird ein selbsterstelltes verschachteltest SELECT Statement verwendet. Ein Beispielstatement befindet sich im Anhang (siehe A.5). Auf der obersten Rekursionsstufe wird der Startknoten des Graphen mitgegeben (in diesem Beispiel ist der Startknoten = 1). Das Ergebnis dieser Abfrage wird als Eingabe für die nächst tiefere Rekursionsstufe verwendet. In der WHERE Klausel wird für die Spalte src der IN Operator verwendet. Der IN Operator erlaubt es, mehrere Werte innerhalb der WHERE Klausel anzugeben. Das

¹Die Überprüfung von Duplikaten erfolgt bezogen auf alle vorherigen Rekursionsstufen

²Ein Weg, bei dem der Anfangsknoten gleich dem Endknoten ist [Bec18, S.48]

DISTINCT in der SELECT Klausel sorgt dafür, dass Duplikate in der Ergebnismenge der momentanen Rekursionsstufe entfernt werden. Die Funktionsweise von DISTINCT ist in der folgenden Grafik nochmal dargestellt:




Abbildung 3.2: Löschen von Duplikaten in einer Rekursionsstufe

Hierbei liegt der Knoten 5 so, dass er in der 2. Rekursionsstufe 2 Mal in der Auswahl auftaucht. DISTINCT entfernt das Duplikat. Die Ergebnismenge, entfernt um die Duplikate, wird als Input für die nächste Rekursionsstufe verwendet. Die Ausgabe des verschachtelten SELECT Statement sind die Nachbarn der Knoten, der angegebenen Rekursionstiefe. Wird zum Beispiel ein verschachteltes SELECT Statement der Tiefe 3 erstellt, so gibt dieses Statement alle Nachbarn 3. Grades ausgehend vom Startknoten an. Der Nachteil bei dieser Methode ist, dass Kreise in einem Graph nicht erkannt werden. Die Duplikatüberprüfung erfolgt nicht über mehrere Rekursionsstufen hinweg, sondern immer nur zwischen zwei Rekursionsstufen.

3.1.7 Graphtraversierung mit Hilfe von rekursiven INNER JOIN

Bei der Graphtraversierung mit Hilfe von rekursiven INNER JOIN soll der Graph traversiert werden, indem die Relationentabelle immer wieder mit sich selber verknüpft wird. Die Ausgabe ist, ähnlich wie bei der Graphtraversierung mit Hilfe von verschachteltem SELECT Statement, die Nachbarn der Knoten, die sich auf der mitgegebenen Rekursionstiefe befinden. Ein Beispielstatement für den rekursiven INNER JOIN ist im Anhang gegeben (siehe A.6).

3.1.8 Graphtraversierung mit Hilfe von selbstgeschriebenen Stored Procedure

Bei der Graphtraversierung mit Hilfe von selbstgeschriebenen Stored Procedure wird der Graph mit Hilfe eines selbst erstellten Stored Procedure, das sich selber bis zu

einer mit gegebenen Rekursionstiefe wieder aufruft, traversiert (siehe A.7). Die Abbruchbedingung wird dem Stored Procedure in Form einer Rekursionsstiefe mitgegeben. In jeder Rekursionsstufe erstellt das Script 2 temporäre Tabelle. Eine temporäre Tabelle³ wird auf Basis eines Eingabeparameter (Datenstruktur Array) erstellt. Diese temporäre Tabelle besitzt eine Spalte. Diese Tabelle stellt die Spalte src der aktuellen Rekursionsstufe dar. Sie wird im IN Operator der WHERE Klausel verwendet um die 2. temporäre Tabelle zu erstellen. Die 2. temporäre Tabelle beinhaltet die Spalte dst der aktuellen Rekursionsstufe. Die 2. temporäre Tabelle wird als Aufrufparameter für die nächst tiefere Rekursionsstufe mitgegeben. In der nächst tieferen Rekursionsstufe dient die 2. temporäre Tabelle als die Tabelle, die alle src Spalten der aktuellen Rekursionsstufe beinhaltet.

³Zuerst wurde das Script mit Hilfe einer standard Tabelle erstellt. Dadurch war das Stored Procedure jedoch um den Faktor 7 langsamer. Es ist die Vermutung, dass durch die Anlage als temporäre Tabelle, die Tabelle im Shared Memory angelegt wird. Hierdurch wird der Performancegewinn erzielt ([Fro18, S.26])

4 Graph-Datenbanken im praktischen Einsatz: OLAP

4.1 PostgreSQL: OLAP

4.1.1 Benchmark

Mit der Standardinstallation von PostgreSQL wird auch pgbench mitinstalliert. Bei pgbench handelt es sich um ein einfaches Tool zur Durchführung von Benchmark-Tests. Bei einem Benchmark-Test wird eine Menge von SQL-Statements beliebig oft wiederholt, dabei können auch mehrere parallele Sessions geöffnet werden. Beim durchführen des Tests berechnet pgbench die Anzahl der Transaktionen pro Sekunde.

Verwendung von pgbench

pgbench wird über die Kommandozeile gestartet. Dabei können eine Reihe von Parametern übergeben werden, mit denen das Verhalten von pgbench gesteuert werden kann.

- -c clients
Über das Flag -c wird die Anzahl der Clients bzw. die Anzahl der gleichzeitigen Datenbankverbindungen festgelegt. Wenn hier nichts angegeben ist wird nur ein Client verwendet.
- -t transactions
Über das Flag -t wird festgelegt wieviele Transaktionen jeder Client durchführt. Die Anzahl aller Transaktionen ergibt sich durch das Produkt von Clients und Transactions.


Antwortzeiten ohne Indices

Abbildung 4.1: public_epinions

Rekursions- tiefe	Laufzeit in MS			
	selectSource CodeGenerator	recursiveSearch	recursive WithUnion	selectInner JoinGenerator
1	63.636	89.858	59.275	61.065
2	139.225	168.822	143.367	231.850
3	229.997	273.452	277.766	333.011
4	432.297	513.038	1664.168	17772.456
5	677.420	921.228	8335.513	81241.284




Abbildung 4.2: public_livejournal

Rekursions- tiefe	Laufzeit in MS			
	selectSource CodeGenerator	recursiveSearch	recursive WithUnion	selectInner JoinGenerator
1	4761.733	7075.399	4695.466	4909.862
2	11589.219	13702.381	41616.216	24417.787
3	24971	20773.831	64577.873	31563.339
4	44625.935	28048.866	87434.075	37785.200
5	65632.972	53825.401	115432.071	56601.185




Abbildung 4.3: public_facebook

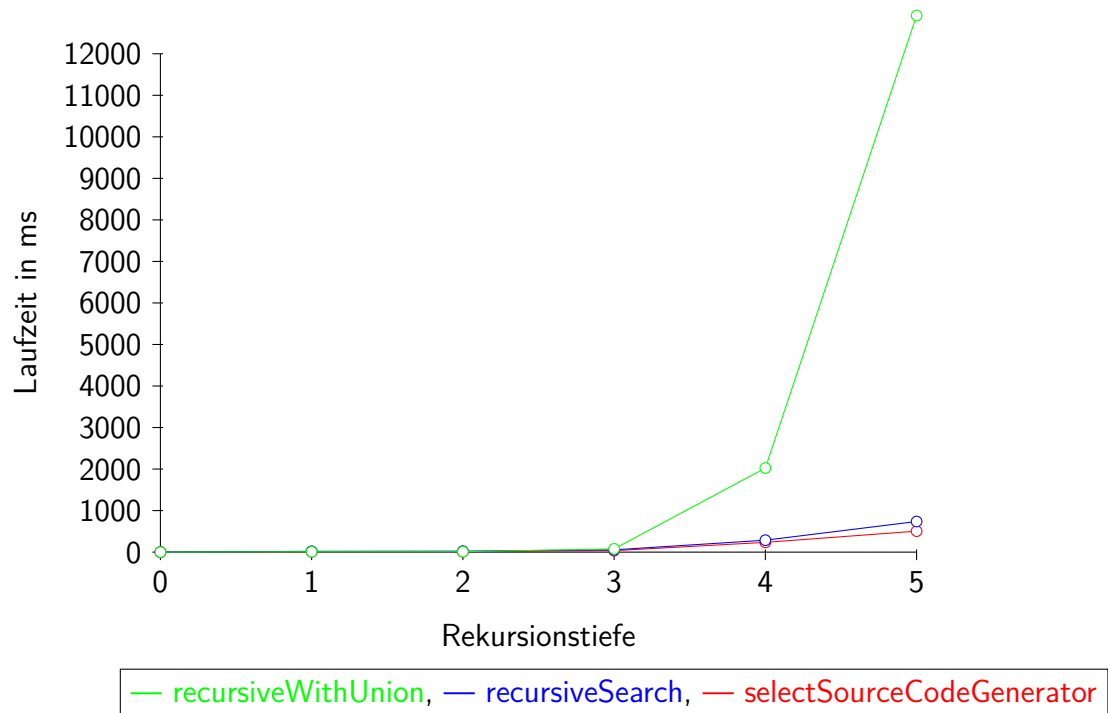
Antwortzeiten mit Indices

Abbildung 4.4: public_epinions

Rekursionstiefe	Laufzeit in MS		
	selectSourceCodeGenerator	recursiveSearch	recursiveWithUnion
1	8.231	18.999	8.855
2	9.290	23.549	10.304
3	36.244	54.953	78.303
4	235.146	287.319	2024.069
5	504.793	737.300	12920.747




Abbildung 4.5: public_livejournal




Abbildung 4.6: public_facebook

4.1.2 Antwortzeiten mit partitionierten Tabellen und Indices

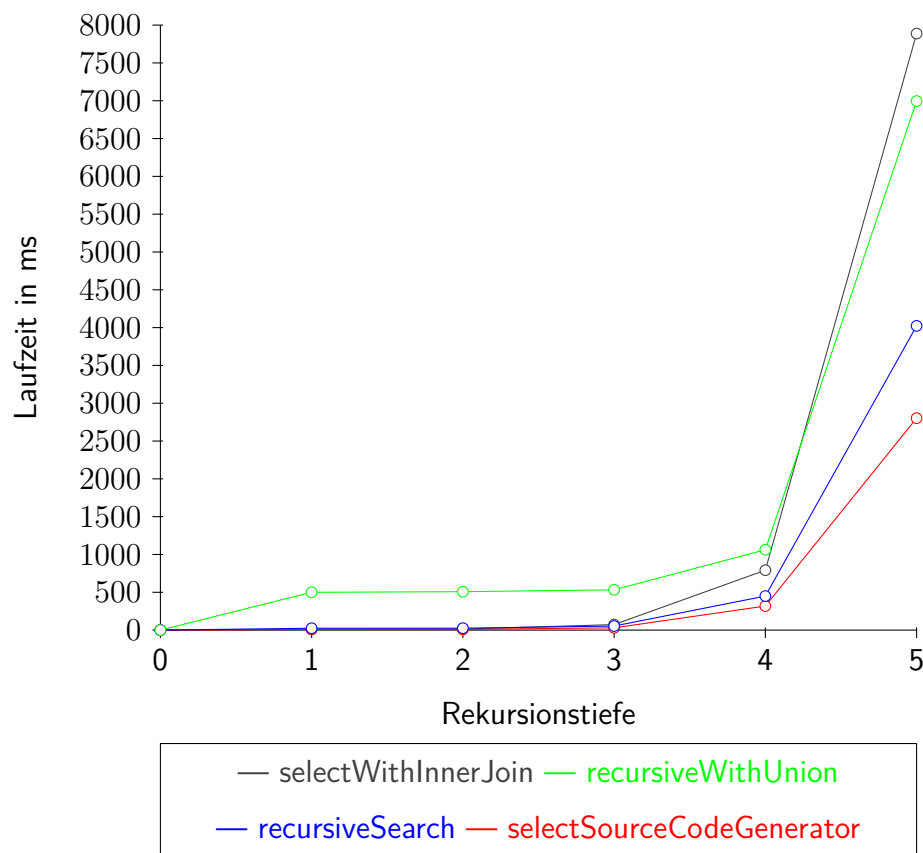


Abbildung 4.7: public_livejournal

4.1.3 Standard SQL

4.1.4 Stored Procedures

4.1.5 PL/SQL-Recursion

4.1.6 Datenbankzugriffe

4.1.7 Zugriffsart Aggregation

4.1.8 Zugriffsart Traversierung

4.1.9 Interpretation der Ergebnisse

A Anhang

A.1 Graph-Datenbanken - Grundlegende technologische Aspekte

A.2 Graph-Datenbanken und -Frameworks - Ausgewählte Systeme




Abbildung A.1: Postgres Architektur

A.3 Graph-Datenbanken im praktischen Einsatz: OLTP

Listing A.1: CSV Input

```
\copy Beitraege
FROM './data/Beitraege.csv' DELIMITER ',' CSV HEADER;
```

Listing A.2: Anlegen der Tabelle facebook-profiles

```
create TABLE IF NOT EXISTS profiles_facebook(  
    ID INTEGER PRIMARY KEY,  
    first VARCHAR(50),  
    last VARCHAR(50),  
    gender GENDER,  
    birth DATE,  
    country VARCHAR(50)  
);
```

Listing A.3: Anlegen der Tabelle facebook-relation

```
CREATE TABLE IF NOT EXISTS relation_facebook(  
    src INTEGER REFERENCES profiles_facebook(ID),  
    dst INTEGER REFERENCES profiles_facebook(ID),  
    type VARCHAR(50),  
    date DATE  
);
```

Listing A.4: Hinzufügen von Fremdschlüsseln

```
\copy profiles_facebook_tmp(first,last,gender,birth,country) FROM '/data/WS2018/  
facebook-profiles' DELIMITER ',' CSV HEADER;  
INSERT INTO profiles_facebook (ID, first, last, gender, birth, country)  
SELECT ID-1, first, last, gender, birth, country from profiles_facebook_tmp;
```

Listing A.5: Verschachteltes SELECT Statement

```
SELECT DISTINCT(dst) FROM team22.relation_facebook WHERE src IN(  
    SELECT DISTINCT(dst) FROM team22.relation_facebook WHERE src IN(  
        SELECT DISTINCT(dst) FROM team22.relation_facebook WHERE src IN(1)  
    )  
);
```

Listing A.6: Rekursiver JOIN

```
SELECT DISTINCT(rf3.dst)  
FROM public.relation_facebook rf1,  
public.relation_facebook rf2,  
public.relation_facebook rf3  
WHERE rf2.src = rf1.dst  
AND rf3.src = rf2.dst  
AND rf1.src = 765;
```

Listing A.7: Selbstgeschriebenes Stored Procedure

```

CREATE OR REPLACE FUNCTION recursivesearch(tInput integer[], iRecursionDepth
integer, sTable text) RETURNS SETOF integer AS $$
Declare
intermDst_ integer[];
iCount integer;
BEGIN
--iRecursionDepth = iRecursionDepth + 1;
CREATE TEMPORARY TABLE intermDst AS SELECT * FROM unnest(tInput);
EXECUTE 'CREATE TEMPORARY TABLE intermDst1 AS SELECT DISTINCT(dst) FROM ' || sTable
|| ' WHERE src IN (SELECT * FROM intermDst)';
-- Does not return from function!
return query SELECT * FROM intermDst1;
-- Does not return from function!
intermDst_ := ARRAY(SELECT * FROM intermDst1);
raise notice 'timestamp: %', clock_timestamp();
SELECT count(*) INTO iCount FROM intermDst;
raise notice 'Count Table: %', iCount;
DROP TABLE intermDst;
DROP TABLE intermDst1;
-- As recursion depth is 5
if iRecursionDepth > 1 THEN
return query SELECT * FROM recursivesearch(intermdst_, iRecursionDepth - 1, sTable)
;
ELSE
RETURN;
END IF;
END;
$$ LANGUAGE plpgsql;

```

Listing A.8: SQL Standard SQL Mittel

```

CREATE OR REPLACE FUNCTION selectWithUnionSourceCodeGenerator_withDepth(sTable text
, startingNode integer, depth integer ) RETURNS SETOF integer AS $$
Declare
intermDst_ integer[];
tStatement text;
tSelectStatement text;
tWithStatement text;
tUnionStatement text;
tWithStatementClose text;
BEGIN
tWithStatement := 'WITH RECURSIVE graphtraverse(src, dst, lvl) AS(';
tSelectStatement := 'SELECT src ,dst, 1 as lvl FROM ' || sTable || ' WHERE src =' ||
startingNode;
tUnionStatement := ' UNION SELECT p1.src,p1.dst,p.lvl+1 as lvl FROM graphtraverse p
, ' || sTable || ' p1 WHERE p1.src IN ( p.dst ) and lvl<' || depth;
tWithStatementClose := ') SELECT DISTINCT(dst) FROM graphtraverse';
tStatement := tWithStatement || tSelectStatement || tUnionStatement ||
tWithStatementClose;
raise notice 'Execute String %', tStatement;
return query EXECUTE tStatement;
END;
$$ LANGUAGE plpgsql;

```

A.4 Graph-Datenbanken im praktischen Einsatz: OLAP

Abbildungsverzeichnis

3.1	Traversierung Standard SQL	10
3.2	Löschen von Duplikaten in einer Rekursionsstufe	11
4.1	public_epinions	14
4.2	public_livejournal	15
4.3	public_facebook	16
4.4	public_epinions	17
4.5	public_livejournal	18
4.6	public_facebook	19
4.7	public_livejournal	20
A.1	Postgres Architektur	21

Tabellenverzeichnis

Listings

A.1	CSV Input	21
A.2	Anlegen der Tabelle facebook-profiles	22
A.3	Anlegen der Tabelle facebook-relation	22
A.4	Hinzufügen von Fremdschlüsseln	22
A.5	Verschachteltes SELECT Statement	22
A.6	Rekursiver JOIN	22
A.7	Selbstgeschriebenes Stored Procedure	23
A.8	SQL Standard SQL Mittel	23

Abkürzungsverzeichnis

ACID	Atomicity, Consistency, Isolation, Durability
API	Application Programming Interface
APT	Advanced Package Tool
CRUD	Create, Read, Update, Delete
CTE	Common Table Expression
IP	Internet Protocol
TCP	Transmission Control Protocol
MVCC	Multiversion Concurrency Control Modell
NoSQL	Not only SQL
OLTP	Online Transaction Processing
RPM	Red Hat Package Manager
SQL	Structured Query Language

Literaturverzeichnis

- [Ang12] ANGLES, Renzo: A comparison of current graph database models. In: *Data Engineering Workshops (ICDEW)*, 2012 IEEE 28th International Conference on IEEE, 2012, S. 171–177
- [APPDSLP13] ANGLES, Renzo ; PRAT-PÉREZ, Arnau ; DOMINGUEZ-SAL, David ; LARRIBA-PEY, Josep-Lluís: Benchmarking database systems for social network applications. In: *First International Workshop on Graph Data Management Experiences and Systems* ACM, 2013, S. 15
- [AU95] AHO, Alfred V. ; ULLMAN, Jeffrey D.: *Foundations of computer science*. USA : Computer Science Press, 1995 <http://infolab.stanford.edu/~ullman/focs.html>
- [Bec18] BECKER, Peter: *Graphentheorie*. <http://www2.inf.h-brs.de/~pbecke2m/graphentheorie/einfuehrung.pdf>. Version: 2018
- [Eis03] EISENTRAUT, Peter: *PostgreSQL Das Offizielle Handbuch*. mitp-Verlag GmbH/Bonn, 2003
- [Fel03] FELSNER, Stefan: *Geometric graphs and arrangements: some chapters from combinatorial geometry*. Springer Science & Business Media, 2003
- [Fro18] FROEHLICH, Lutz: *PostgreSQL 10*. Carl Hanser Verlag München, 2018
- [Goe15] GOEBEL, Christopher: NoSQL - FlockDB. (2015)
- [Groat] GROUP, The PostgreSQL Global D.: *PostgreSQL 11.1 Documentation*. <https://www.postgresql.org/files/documentation/pdf/11/postgresql-11-A4.pdf>
- [Grob] GROUP, The PostgreSQL Global D.: *PostgreSQL 11.1 Documentation*. <https://www.postgresql.org/docs/11/queries-with.html>
- [Groc] GROUP, The PostgreSQL Global D.: *PostgreSQL 8.4 Documentation*. <https://www.postgresql.org/docs/8.4/datatype.html>
- [Gru17] GRUCIA, Jelena: *PostgreSQL and GraphQL*. <https://blog.cloudboost.io/postgresql-and-graphql-2da30c6cde26>. Version: 2017

- [KHA⁺16] KUCUK, Ahmet ; HAMDİ, Shah M. ; AYDIN, Berkay ; SCHUH, Michael A. ; ANGRYK, Rafal A.: Pg-Trajectory: A PostgreSQL/PostGIS based data model for spatiotemporal trajectories. In: *2016 IEEE International Conferences on Big Data and Cloud Computing (BDCloud), Social Computing and Networking (SocialCom), Sustainable Computing and Communications (SustainCom)(BDCloud-SocialCom-SustainCom)* IEEE, 2016, S. 81–88
- [KK15] KNAUER, U. ; KNAUER, K.: *Diskrete und algebraische Strukturen - kurz gefasst*. Springer Berlin Heidelberg, 2015
- [KN12] KRUMKE, S.O. ; NOLTEMEIER, H.: *Graphentheoretische Konzepte und Algorithmen*. Vieweg+Teubner Verlag, 2012 (Leitfäden der Informatik). – ISBN 9783834822642
- [Kud15] KUDRASS, Thomas: *Taschenbuc Datenbanken*. Fachbuchverlag Leipzig im Carl Hanser Verlag, 2015
- [Pos18] POSTGRESQL GLOBAL DEVELOPMENT GROUP: *PostgreSQL 11.1 Documentation*. <https://www.postgresql.org/docs/11>. Version: 2018
- [Rah17a] RAHMAN, Md. S.: *Basic Graph Theory*. Springer International Publishing, 2017
- [Rah17b] RAHMAN, Saidur: *Basic Graph Theory*. Berlin, Heidelberg : Springer, 2017. – ISBN 978–3–319–49475–3
- [Red12] REDMOND, Eric: *Sieben Wochen, sieben Datenbanken*. O'Reilly Verlag, 2012
- [Sas18] SASAKI, Bryce M.: *Graph Databases for Beginners: The Basics of Data Modeling*. <https://neo4j.com/blog/data-modeling-basics/>. Version: 2018
- [SF05] STEFAN FELSNER, Gesine K. Christine Puhl P. Christine Puhl: *Graphentheorie*. <http://page.math.tu-berlin.de/~felsner/Lehre/GrTh05/Graphentheorie.pdf>. Version: 2005
- [TT16] In: THORSTEN THEOBALD, Sadik I.: *Graphen*. Springer Fachmedien Wiesbaden, 2016
- [ZSHZ18] ZHANG, Hongliang ; SONG, Lingyang ; HAN, Zhu ; ZHANG, Yingjun: *Hypergraph Theory in Wireless Communication Networks*. Springer, 2018

Eidesstattliche Erklärung

Ich versichere an Eides Statt durch meine eigenhändige Unterschrift, dass ich die vorliegende Arbeit selbstständig und ohne fremde Hilfe angefertigt habe. Alle Stellen, die wörtlich oder dem Sinn nach auf Publikationen oder Vorträgen anderer Autoren beruhen, sind als solche kenntlich gemacht. Ich versichere außerdem, dass ich keine andere als die angegebene Literatur verwendet habe. Diese Versicherung bezieht sich auch auf alle in der Arbeit enthaltenen Zeichnungen, Skizzen, bildlichen Darstellungen und dergleichen.

Die Arbeit wurde bisher keiner anderen Prüfungsbehörde vorgelegt und auch noch nicht veröffentlicht.

Sankt Augustin,
den 12. Januar 2019
Ort, Datum

Jennifer Wittling, Rolf
Kimmelman, Jan
Löffelsender